

==== RAPPORT DE NETTOYAGE DE DONNÉES ====

Généré le : 2025-12-11 10:46:03

1) INFO GÉNÉRALE AVANT NETTOYAGE

Shape initial (lignes, colonnes) : (30000, 17)

Colonnes : Ville, Type, Saison_ideale, Activites, Description, Budget_estime, Score_utilisateur, Duree_su

Top 20 des colonnes avec le plus de valeurs manquantes (AVANT) :

Ville 0
Type 0
Saison_ideale 0
Activites 0
Description 0
Budget_estime 0
Score_utilisateur 0
Duree_suggeree 0
Accessibilite 0
Securite_confort 0
Hotel 0
Latitude 0
Longitude 0
GoogleMap_URL 0
Services 0
Rating 0
Prix_nuit 0
dtype: int64

Statistiques descriptives des variables numériques (AVANT) :

	count	mean	std ...	50%	75%	max
Latitude	30000.0	32.561571	2.666089 ...	33.450767	34.061542	35.789007
Longitude	30000.0	-7.050896	2.924779 ...	-6.897326	-5.220291	-1.905488
Rating	30000.0	3.933613	0.650368 ...	3.900000	4.500000	5.000000
Prix_nuit	30000.0	889.652800	544.475394 ...	733.000000	1342.000000	2000.000000

[4 rows x 8 columns]

2) INFO GÉNÉRALE APRÈS NETTOYAGE

Shape après nettoyage (lignes, colonnes) : (30000, 18)

Colonnes : Ville, Type, Saison_ideale, Activites, Description, Budget_estime, Score_utilisateur, Duree_su

Top 20 des colonnes avec le plus de valeurs manquantes (APRÈS) :

Ville 0
Type 0
Saison_ideale 0
Activites 0
Description 0
Budget_estime 0
Score_utilisateur 0
Duree_suggeree 0
Accessibilite 0
Securite_confort 0
Hotel 0

```
Latitude      0
Longitude     0
GoogleMap_URL 0
Services      0
Rating        0
Prix_nuit     0
full_text     0
dtype: int64
```

Statistiques descriptives des variables numériques (APRÈS) :

	count	mean	std ...	50%	75%	max
Latitude	30000.0	32.561571	2.666089 ...	33.450767	34.061542	35.789007
Longitude	30000.0	-7.050896	2.924779 ...	-6.897326	-5.220291	-1.905488
Rating	30000.0	3.933613	0.650368 ...	3.900000	4.500000	5.000000
Prix_nuit	30000.0	889.652800	544.475394 ...	733.000000	1342.000000	2000.000000

[4 rows x 8 columns]

3) IMPACT DES OPÉRATIONS DE NETTOYAGE

Nombre de lignes initial : 30000

Nombre de lignes après suppression doublons + NA Description : 30000

Nombre de lignes supprimées : 0

Distribution de 'Rating' (APRÈS) :

count	30000.000000
mean	3.933613
std	0.650368
min	0.000000
25%	3.400000
50%	3.900000
75%	4.500000
max	5.000000

Name: Rating, dtype: float64

Distribution de 'Prix_nuit' (APRÈS) :

count	30000.000000
mean	889.652800
std	544.475394
min	150.000000
25%	421.000000
50%	733.000000
75%	1342.000000
max	2000.000000

Name: Prix_nuit, dtype: float64

4) INFO TF-IDF

Nombre de documents utilisés pour 'full_text' : 30000

Shape de la matrice TF-IDF : (30000, 1053)

Nombre de features TF-IDF (vocabulaire) : 1053

5) SPLIT TRAIN / TEST

Colonne cible utilisée : Rating
Taille X_train : (24000, 1053)
Taille X_test : (6000, 1053)
Taille y_train : (24000,)
Taille y_test : (6000,)

Distribution de 'Rating' — TRAIN :

count	24000.000000
mean	3.933579
std	0.650073
min	0.000000
25%	3.400000
50%	3.900000
75%	4.500000
max	5.000000

dtype: float64

Distribution de 'Rating' — TEST :

count	6000.000000
mean	3.933750
std	0.651603
min	1.000000
25%	3.400000
50%	3.900000
75%	4.500000
max	5.000000

dtype: float64

Fichiers exportés (train/test) :

- X_train_tfidf.npz
- X_test_tfidf.npz
- y_train.csv
- y_test.csv
- hotels_maroc_30000_equilibres_clean_train.csv
- hotels_maroc_30000_equilibres_clean_test.csv